

熊湘婷

173-6927-9948 | xiangtingxiong@qq.com

AI 应用研发工程师



教育背景

硕士：河海大学 / 电子信息 211 双一流

2024.09-2027.06

本科：湖南中医药大学 / 计算机科学与技术

2020.09-2024.06

在校荣誉：学业一等奖学金、优秀毕业生、14 届创新创业大赛国三、16 届计算机设计大赛国三、英语 CET-6，专利 1 项等

专业技能

- 开发基础**：熟悉 Python 后端开发，掌握 FastAPI、Pydantic、异步任务、线程池、Linux、Git、Docker 等工程技术。
- Agent 技术**：熟悉 Agent 工作流设计，理解 Planning、Memory、Tool Calling、Reflection、上下文管理等核心模块；熟悉 ReAct、Function Calling、MCP、Skill 编排、LangGraph、多智能体协作等技术范式，了解 LangChain、GraphRAG、Coze 等主流框架。
- 模型训练与调优**：熟悉 Prompt Engineering、SFT、LoRA、RAG，具备 OCR、VLM、多模态文档解析任务经验。
- 高并发与 Redis 工程化**：熟悉大模型应用工程化落地，掌握 Redis 缓存、分布式信号量、优先级任务队列、异步请求队列、限流降级、日志监控等机制，具备模型推理超时、批量请求堆积、资源争抢等生产问题优化经验。

实习经历

南京通达海科技股份有限公司 通达海

AI 应用研发工程师

2025.09-2026.05

基于 LangGraph+RAG 的政务投诉智能分诊 Agent

Agent 核心链路设计人

- 项目描述**：面向政务投诉场景，构建端到端智能分诊 Agent，解决人工分诊效率低、重复筛重成本高的核心痛点，实现投诉事件抽取、重复识别、分类分级与工单推荐全流程自动化。
- 核心技术**：LLM、MCP、LangGraph、RAG、Milvus、BM25、向量混合召回与重排
- 主要问题与解决**：
 - 语义召回偏移问题**：投诉文本口语化、结构化输出不稳定、同一工单存在多事件投诉，影响重复投诉工单召回效果。
 - 一阶段**：将原始投诉改按规则进行改写，设计 **Pydantic Schema** 约束输出格式，JSON 输出成功率达 99.5%。
 - 二阶段**：设计事件级语义 **Chunk** 策略，将多事件工单拆分为多个独立事件片段，减少向量语义偏移。
 - 重复筛重低效问题**：政务投诉中存在大量重复事件，人工筛重成本高，还存在关键词匹配召回不全，单次召回耗时较长的问题。
 - 构建了 **Milvus + BM25 + RRF+Cross-Encoder Rerank** 的混合召回重排链路。Milvus 负责语义相似召回，BM25 保证关键词命中，RRF 对双路召回结果进行融合排序，Cross-Encoder 对候选工单进行精排。重复事件识别准确率从 75%提升到 90%。
 - Workflow 分诊流程灵活性不足**：原流程基于固定节点串行编排，事件抽取、判重、分类分级与工单推荐之间缺少状态共享和信息回流。
 - 基于 **LangGraph** 重构状态驱动的多 Agent 分诊链路，设计统一 **Graph State** 管理事件信息、相似事件、分类置信度与推荐结果，通过条件路由实现判重、分类、推荐与人工兜底的动态流转，事件分类准确率达 91%，工单分流效率提升 70%。
 - 高并发超时问题**：前端存在批量请求场景，当瞬时进入多条请求时，模型 token 需求达到十万级，导致推理超时和请求堆积。
 - 一阶段**：单服务实例内引入异步请求队列和固定大小 Worker 池，将前端批量投诉请求拆分为可控小批次执行。
 - 二阶段**：设计全局优先级任务队列 + Redis 分布式信号量。队列负责统一承接批量请求，按任务分类设置优先级；Redis 信号量负责限制真正进入模型的全局并发数，解决多服务实例同时调用模型导致的超时和资源打满问题。

中国南方电网有限责任公司 中国南方电网

算法工程师

2025.02-2025.07

电力文档智能编目引擎-材料信息识别模块

材料信息识别模块负责人

- 项目描述**：面向南方电网生产运维等文档，构建智能识别与编目引擎，解决人工编目效率低、表格识别效果差，实现文档识别准确率 90%+。
- 核心技术**：OCR、VLM、多模态文档解析、SFT、LoRA 微调、标注体系设计与模型评测
- 主要问题与解决**：
 - 数据标准缺失问题**：针对生产运维资料来源多、扫描件质量参差导致初始 OCR 噪声率 35%，及字段解析不稳定的问题。
 - 一阶段**：主导搭建电网文档数据标准化体系，设计专属解析清洗 Pipeline，对图片进行标准化处理、基础质量过滤与 Hash 去重。
 - 二阶段**：定义 DocTags 中间格式，将不同版式文书映射为统一标签体系再解析，补充印章等专属标签，沉淀 4.7 万张高质量标注样本。
 - 垂类适配不足问题**：针对英文基模对中文法律术语适配差、场景识别准确率仅 72%、全参数微调特征漂移的问题。
 - 设计垂类数据 SFT 与视觉层冻结+语言层 LoRA 微调策略。识别准确率提升至 92%，训练显存占用降低 40%。
 - 评测闭环缺失问题**：针对本地标注流程低效、进度不可视、标注一致性难管控，以及模型评测缺少统一标准、低分样本难定位。
 - 一阶段**：主导建设内网在线标注平台，支持任务分配、实时提交、进度追踪与交叉互审，将多人标注一致性从 62%提升至 94%。
 - 二阶段**：构建全链路评测体系，设计 6 类场景 public 测试集 500 张、private 1000 张，支持榜单排名、差异对比与低分 Bad Case 回流。